

DETECCION DE ONDAS GRAVITACIONALES

Andres Villarreal González A00833915


Salvador Vidal Torres A01732983

Gerardo Juárez Hernández A01732799




CONTEXTO

La detección de ondas gravitacionales marca un avance monumental en la astrofísica, proporcionando información sobre la dinámica de eventos cósmicos masivos como las fusiones de agujeros negros y colisiones de estrellas, estas ondas ofrecen una nueva ventana de observación del universo que permitirá a los científicos investigar la naturaleza fundamental de la gravedad y el comportamiento de la materia en condiciones extremas.



PROBLEMÁTICA



El desafío principal de nuestro proyecto radica en detectar estas señales increíblemente débiles contra un fondo de ruido sustancial, que surge tanto de fuentes terrestres como cósmicas.


Por lo tanto, mejorar la robustez y precisión de la detección de ondas gravitacionales es fundamental para avanzando en nuestra comprensión del universo

Objetivos:

- Desarrollar un método de detección robusto integrando TDA y CNN.
- Mejorar la precisión de detección en ambientes con bajo ratio señal-ruido

Hipótesis:

La integración de características topológicas derivadas de TDA con CNN aumentará la precisión y robustez en la detección de ondas gravitacionales comparado con métodos tradicionales.



Marco Teorico



Ondas Gravitacionales



Homología Persistente



**Redes Neuronales
Convolucionales (CNN)**

Metodología

Generación de Datos Sintéticos



Sliding Window y Reducción de dimensionalidad



Aplicación del TDA



Preprocesamiento de Datos



Entrenamiento de la CNN



Prueba Estadística

Generación de Datos Sintéticos




Archivo de señales gravitacionales limpias

$$+ \underbrace{\epsilon * \frac{1}{R} * \xi}_{\text{Ruido}}$$

$$\epsilon = 10^{-19}$$

ξ = Ruido Gaussiano

$$\text{SNR} = \frac{1}{R} = \frac{\text{Potencia de la señal}}{\text{Potencia del ruido}}$$

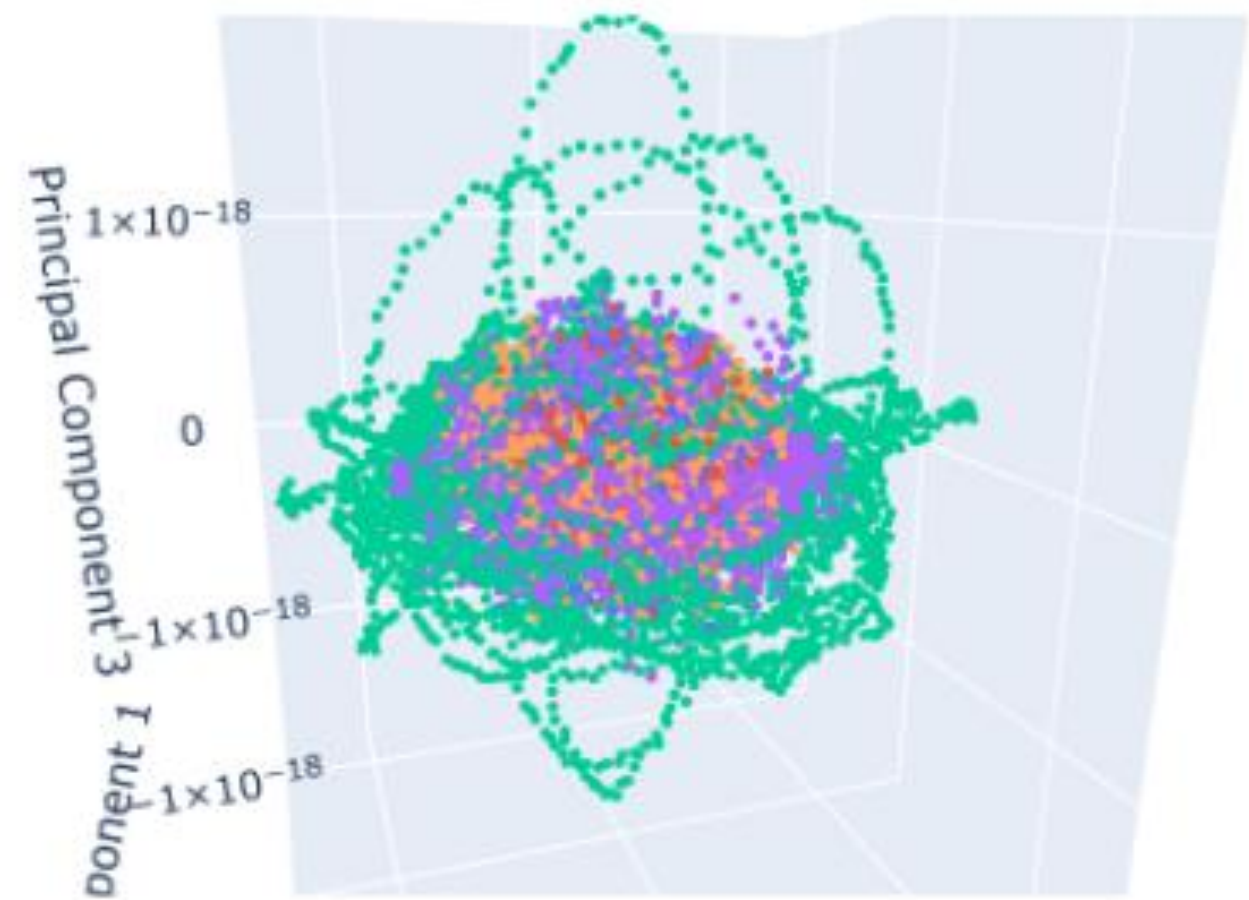


Sliding Window y reduccion de dimensionalidad

- **Embedding de Ventana Deslizante: Conversión de series temporales.**
- **Análisis de Componentes Principales (PCA): Reducción de dimensionalidad.**


Visualización

La visualización resultante de este proceso nos permite observar los datos en un espacio reducido en 3D, lo que facilita la interpretación y el análisis.



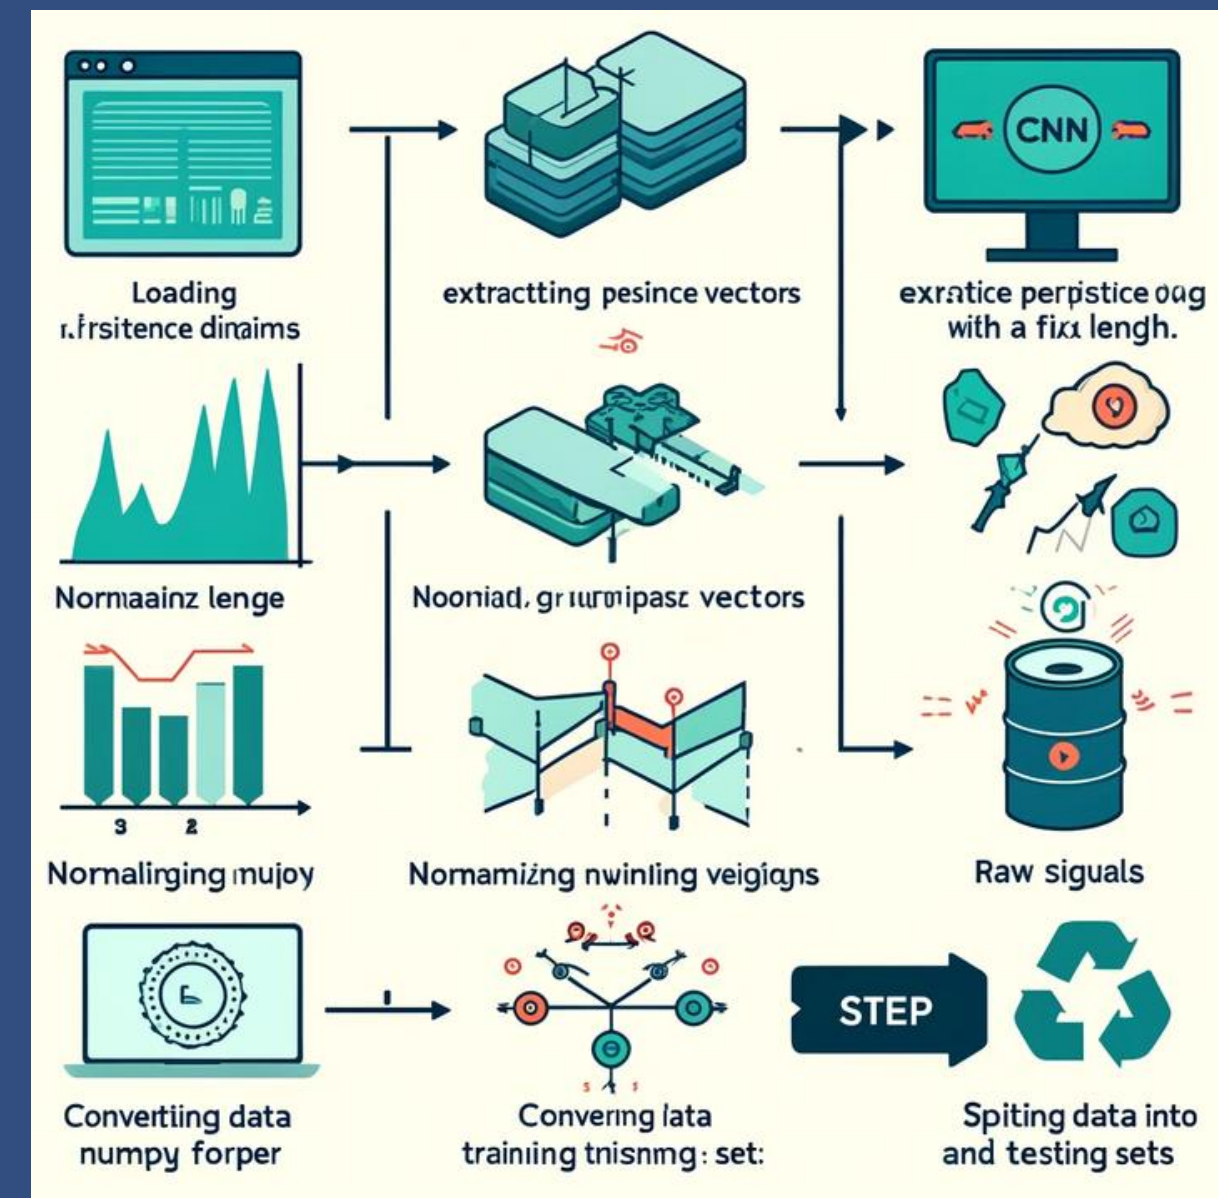
Aplicación del TDA

- Homología Persistente
- Diagramas de Persistencia
- Complejo de Vietoris - Rips



Preprocesamiento de Datos

- Carga de diagramas de persistencia
- Extracción de vectores de persistencia
- Normalización de vectores
- Normalización de señales crudas
- Concatenación de vectores y señales crudas
- Conversion de datos a numpy
- Division en entrenamiento y prueba



Entrenamiento del CNN

Integración de características topológicas y señales originales para entrenar la CNN.

13 Capas :

- Conv1D
- MaxPooling1D
- Dropout
- Conv1D
- MaxPooling1D
- Dropout
- Conv1D
- MaxPooling1D
- Dropout
- Flatten
- Dense
- Dropout
- Dense

Ajuste de hiperparámetros:

- Tasa de aprendizaje: 0.001
 - Tamaño de lote: 32
 - Número de épocas: 20
 - Optimizador: Adam

Prueba Estadística

H_0 : La precisión del modelo se debe al azar.
Esto implica que no existe una relación
real entre las características de
entrada y las etiquetas.


H_1 : La precisión del modelo es
significativamente mayor de lo que se
esperaría por azar. Esto implica que
existe una relación genuina entre las
características de entrada y las
etiquetas

Valor p: 0.023809523809523808
Distribución nula: 0.7997200279972003

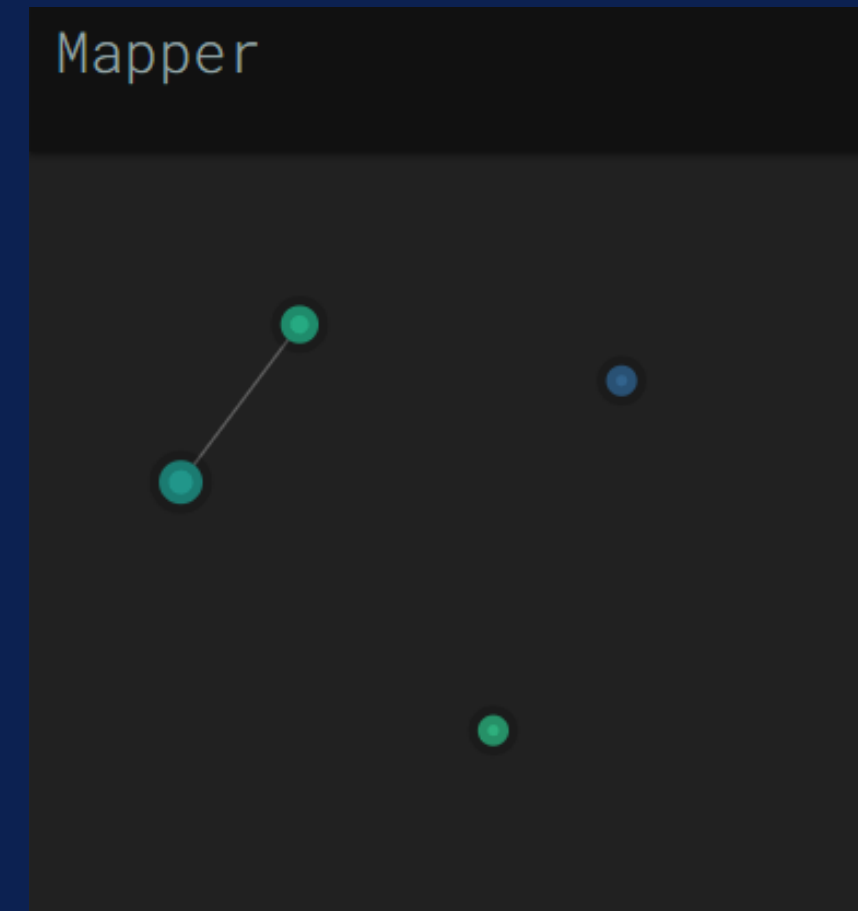
$$\alpha = 0.02$$

$$\alpha < 0.05$$

Resultados




Test Accuracy: 85.54%



Conclusiones:

El enfoque propuesto ofrece una mejora significativa en la robustez y precisión de la detección de ondas gravitacionales.

La combinación de TDA y CNN presenta un avance en la capacidad de detectar señales débiles en la astronomía de ondas gravitacionales.



¡MUCHAS GRACIAS!